



Trabajo Práctico 2

Clasificación y Selección de Modelos

2 de marzo de 2024

Laboratorio de Datos

Grupo 100

Integrante	LU	Correo electrónico
Apellido, Nombre1	001/01	email1@dominio.com
Martinelli, Lorenzo	364/23	martinelli.lorenzo12@gmail.com
Padilla, Ramiro	1636/21	ramiromdq123@gmail.com



Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (+54 +11) 4576-3300

<http://www.exactas.uba.ar>

1. Introducción

1.1. Fuente de datos

A lo largo de este proyecto, trabajaremos con un conjunto de datos de imágenes denominado Sign Language MNIST¹, el cual se encuentra en formato csv, donde cada imagen del set de datos representa una letra en lenguaje de señas americano. El link al dataset se encuentra al pie de página.

1.2. Análisis exploratorio de datos

Antes de ponernos a trabajar con los datos, necesitamos saber mas acerca de ellos. Sabemos que, cada fila del dataset representa una imagen de 28x28 pixeles en escala de grises que corresponde a una letra en lenguaje de señas. Miremos a continuación un pequeño fragmento del mismo. En este, podremos ver las semejanzas y diferencias que tenemos entre las distintas letras. También, se puede ver en menor medida similitudes entre letras de la misma clase.

Preview del dataset

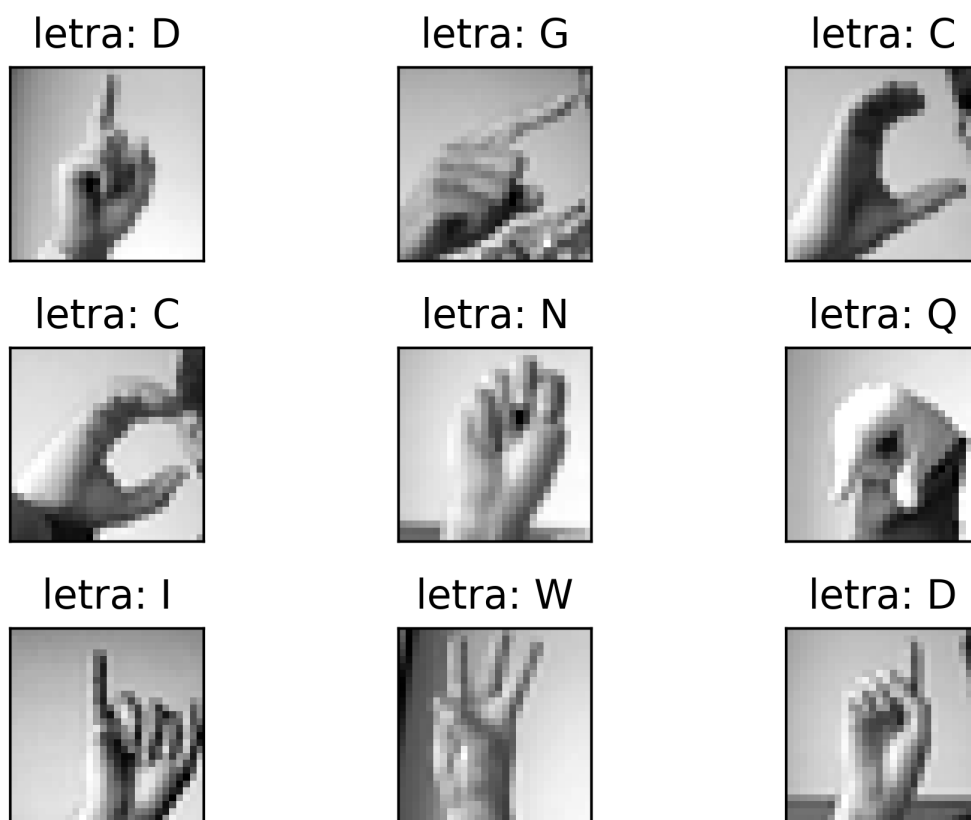


Figura 1: Primeras nueve imagenes del dataset

A partir del gráfico anterior, podemos inferir que no todos los pixeles son realmente relevantes para diferenciar imágenes entre si. Por ejemplo, podemos ver que aquellos pixeles correspondientes al fondo no aportan información alguna. ¿Cuántos pixeles necesitaremos realmente para diferenciar las imágenes?

Por otro lado, viendo por ejemplo, que las letras C y D aparecen más de una vez, también surge la pregunta. ¿Están balanceadas las distintas clases que identifican a las letras? En el gráfico a continuación, podremos notar que tenemos un dataset con una excelente distribución de clases. ¿Por qué me interesa tener una cantidad pareja de cada muestra? Esto, adquiere relevancia puesto que al entrenar nuestros modelos en un futuro, no queremos tener sesgos.

Obs: Las letras J y Z no poseen ningún ejemplar puesto que requieren de movimiento para su seña.

¹Link al dataset <https://www.kaggle.com/datasets/datamunge/sign-language-mnist>


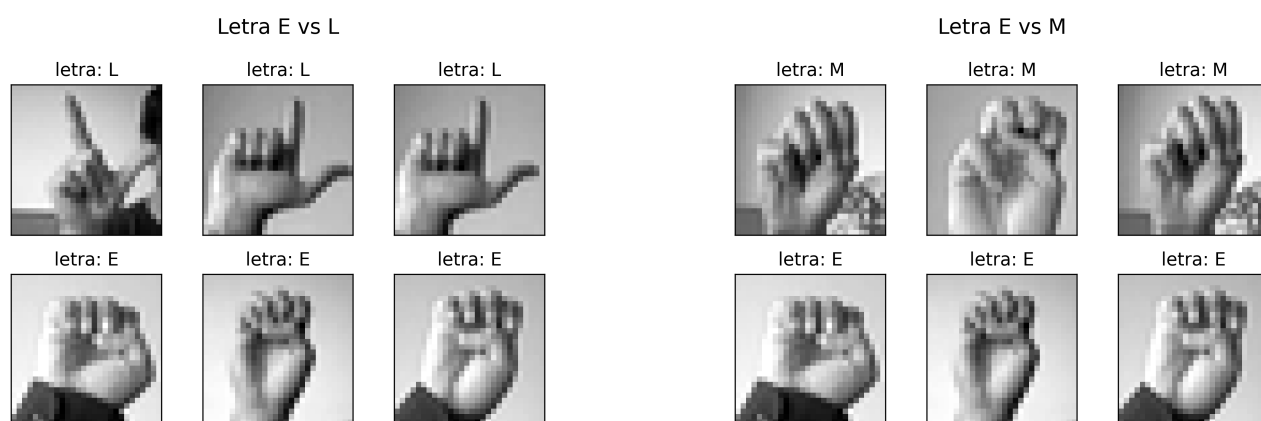


Figura 2: Cantidad de muestras de cada letra


Otra pregunta que naturalmente surge al explorar el dataset es que tan distintas son las letras entre sí, y si las diferentes muestras respecto a una misma letra presentan diferencias notorias o no. Para eso, comparemos por ejemplo, las letras E, L y M.




(a) Muestras de las letras E y L

(b) Muestras de las letras E y M

En la imagen anterior, podemos apreciar que tanto la letra E como la M son muy distintas a la letra L, sin embargo, poseen muchas semejanzas entre sí. Esto, es algo a tener en cuenta a la hora de plantear los modelos, cuales serán los píxeles mas representativos para imágenes similares. Miremos también, si en imágenes pertenecientes a una misma letra hay diferencias notorias.



(a) Distintas muestras de la letra C



(b) Todas las muestras de la letra C apiladas


Si bien, a simple vista, cuando comparamos algunos ejemplares, pareciera que las diferencias pueden llegar a ser significativas, a la hora de comparar todos los ejemplares, en este caso, apilándolos, notamos que forman una silueta que representa muy bien la seña a la que corresponde.

A partir de todo el análisis anterior, pudimos notar que no representa diferencias significativas el trabajar con imágenes respecto a datasets como el del titanic, respecto a su dificultad. Si, quizás, lleva algo mas de tiempo su análisis, pero con las herramientas indicadas no presenta mayores dificultades.


2. Modelo

2.1. ¿La imagen corresponde a una seña de la L o a una seña de la A?

En esta sección, trabajaremos con un subconjunto del dataset original, donde solo esten la letra A y L. Nuestro objetivo, será encontrar un modelo que diferencie con la menor cantidad de píxeles posibles. Comencemos entonces, viendo las diferencias entre estas letras y cuantas muestras tenemos.



(a) Todas las letras A y L apiladas y reescaladas



(b) Cantidad por clase

Sabemos entonces, que tenemos buena distribución, y podemos ver de la imagen de la izquierda que parecería que hay dos zonas que diferencian bien ambas letras, lo que vamos a hacer entonces es 'restar' ambas letras para así encontrar donde están

los pixeles de mayor varianza. ¿Por qué los de mayor varianza? Puesto que son aquellos que representan mas la diferencia entre ambas imagenes.

Varianza entre A y L





Figura 6: Letra L - A


Notamos que, la zona con mayor varianza seria en la zona mas oscura que aparece en el medio de la imagen o, en su defecto, la zona mas blanca. Para saber esto con precisión utilizamos una función de pandas que nos devuelve en una lista las 10 posiciones con los valores mas altos. Destacando, que los pixeles mas representativos son el 301, 274 y 246.

2.2. Construcción del Modelo

Una vez, que conocemos bastante acerca de nuestro dataset, estamos en condiciones de armar nuestro clasificador Knn. A fines de afinar nuestro modelo, hicimos pruebas utilizando distintas cantidades de pixeles, la idea es, utilizar la menor cantidad posible para asi no usar datasets tan grandes. Como ya conociamos aquellos pixeles mas significativos, hicimos pruebas utilizando 1, 3 y 50 pixeles tomando a su vez, distinta cantidad de vecinos. A continuación tenemos los resultados.




(a) 50 pixeles en una zona no tan significativa




(b) Los 3 pixeles mas significativos

Notemos que, a diferencia de lo que marca la intuición, la mejor cantidad de vecinos es 1 en ambos casos. Por otro lado, podemos notar que no es necesaria una gran cantidad de pixeles, sino que solamente con 3 pixeles que sean relevantes podemos tener un modelo con mas del 0.99 de precisión.



(a) Pixeles de alta varianza



(b) Pixeles de baja varianza

Sin embargo, hay un caso que escapa a la regla. Encontramos que cuando tenemos solo un pixel. Sin importar si este es significativo o no, la performance del modelo tiende a aumentar a medida que el numero de vecinos es mayor. En este caso, a partir de los gráficos, pareciera ser que $k = 9$ sería un buen número.

Cerrando esta sección, creo que podemos concluir que tomando los 3 pixeles de mayor varianza y $k = 1$, tenemos un excelente clasificador para distinguir entre la letra A y la letra L.

3. Clasificador Multiclase